چارچوب راستی‌آزمایی ادعامحور مبتنی بر شواهد برای تشخیص توهم در سامانه‌های RAG

چکیده

تولید تقویت‌شده با بازیابی (RAG) پاسخ مدل‌های زبانی بزرگ را به اسناد بیرونی متصل می‌کند، اما بازیابی سند مرتبط تضمین نمی‌کند که همه گزاره‌های پاسخ از آن سند پشتیبانی شوند. چالش اصلی آن است که پاسخ ممکن است شواهد را نادیده بگیرد، منابع متعارض را نادرست جمع‌بندی کند یا اطلاعاتی فراتر از متن بازیابی‌شده بیفزاید، و ارزیابی در سطح کل پاسخ منشأ این خطاها را روشن نمی‌کند. در این پ‌ژوهش چارچوبی مستقل و قابل ممیزی برای راستی‌آزمایی پس از تولید ارائه می‌شود که پاسخ را به ادعاهای اتمی تقسیم می‌کند، شاهد را همراه با شناسه و منشأ منبع به هر ادعا پیوند می‌دهد و با داور مستقل یکی از سه وضعیت «پشتیبانی‌شده»، «متناقض» یا «فاقد شواهد کافی» را ثبت می‌کند؛ سپس ادعا حفظ یا اصلاح می‌شود، بازیابی هدفمند تکرار می‌شود یا سامانه از پاسخ قطعی خودداری می‌کند. طراحی بر مرور 25 منبع پ‌ژوهشی استوار است. برای ارزیابی آتی، مجموعه‌داده‌های RAGTruth، FRAMES و HaluBench با معیارهای دقت، فراخوانی و F1 در سطح ادعا، صحت ارجاع، کیفیت خودداری و هزینه اجرا پیشنهاد می‌شوند. چون چارچوب هنوز پیاده‌سازی و آزمون نشده است، هیچ مقدار عددی برای عملکرد آن گزارش نمی‌شود.

کلمات کلیدی

تولید تقویت‌شده با بازیابی، تشخیص توهم، راستی‌آزمایی شواهد، تجزیه ادعا، ارزیابی واقع‌مندی، قابلیت ردیابی

مقدمه

تصور کنید از یک دستیار هوشمند درباره یک سند پزشکی یا حقوقی می‌پرسید و پاسخی روان، منسجم و قانع‌کننده می‌گیرید؛ اما آیا هر جمله آن واقعاً در سند آمده است؟ مدل‌های زبانی بزرگ در پاسخ‌گویی به پرسش‌ها، خلاصه‌سازی، تحلیل اسناد و سامانه‌های پشتیبان تصمیم به کار می‌روند، اما روانی متن و انسجام پاسخ نشانه کافی برای درستی واقعی آن نیست و خروجی ممکن است گزاره‌ای نادرست، ساختگی یا فاقد پشتوانه در متن مبنا داشته باشد [1]. Huang و همکاران توهم را مفهومی چندوجهی می‌دانند و میان ناهماهنگی با واقعیت بیرونی و ناهماهنگی با زمینه یا دستور تمایز می‌گذارند [1]. برای مهار این خطا، تولید تقویت‌شده با بازیابی (RAG) مرحله بازیابی را به فرایند تولید می‌افزاید تا پاسخ به منابع بیرونی متصل شود. اما پیوند یک پاسخ با مجموعه‌ای از اسناد ثابت نمی‌کند که هر ادعای آن از همان اسناد پشتیبانی می‌شود: سند بازیابی‌شده ممکن است مرتبط باشد اما فقط بخشی از پاسخ را پوشش دهد، منابع معتبر ممکن است با هم تعارض داشته باشند و پاسخ ممکن است جزئیاتی بیفزاید که در هیچ منبعی نیست.

منشأ خطا نیز همیشه مدل مولد نیست. اطلاعات پرنویز و تکراری استدلال مدل را مختل می‌کند و برای کاهش آن در یک مطالعه پزشکی روشی ارائه شده است [6]. استفاده مستقیم از خروجی خام OCR می‌تواند پرسش‌وپاسخ مبتنی بر RAG را مختل کند، حتی وقتی دقت تشخیص متن بالاست [5]. دانش مخرب واردشده به مخزن می‌تواند عملکرد سامانه را از مسیر درست خارج کند [7]. روش بازیابی، بازرتبه‌بندی و معیار شباهت نیز بر نتیجه اثر دارند [12]. هر یک از این خطاها در مرحله‌ای متفاوت رخ می‌دهد، پس ارزیابی صرفِ ارتباط اسناد بازیابی‌شده یا صحت کلی پاسخ

نمی‌گوید کدام ادعا بی‌پشتوانه است و چرا.

حتی خود ارزیابی هم ساده نیست. معیارهای خودکار واقع‌مندی با یکدیگر ناسازگارند و نسبت به بازگویی‌های معنایی سوگیری دارند [13]. آشکارسازهای مبتنی بر نمایش با تغییر توزیع داده افت می‌کنند [14]. کیفیت ارزیابی نباید به یک عدد یا یک داور خودکار تقلیل یابد [10]. در کاربردهای صنعتی نیز راهکار کاهش توهم باید با زمینه کاربرد سازگار شود [11]. برای سنجش تجربی، RAGTruth نزدیک به 18000 پاسخ تولیدشده را با برچسب انسانی در سطح پاسخ و قطعه فراهم کرده است [18]. مجموعه FRAMES نیز پرسش‌هایی را می‌سنجد که به واکشی و ترکیب چندمرحله‌ای اطلاعات نیاز دارند [15]. مجموعه HaluBench حدود 15000 سه‌تایی زمینه ـ پرسش ـ پاسخ را از شش مجموعه، از جمله RAGTruth، با برچسب وفاداری گرد آورده و در پژوهشی درباره وفاداری RAG به کار رفته است [21]. برچسب‌های آن در سطح پاسخ است و برای ارزیابی در سطح ادعا باید با تجزیه ادعا تکمیل شود.

اینجاست که داستان ما آغاز می‌شود: هر ادعا باید جداگانه، با شاهد مشخص و با تصمیمی قابل ردیابی بررسی شود. وجود شاهد ناقض با نبود شاهد یکی نیست؛ تعارض مستند می‌تواند نشانه نادرستی ادعا باشد، اما نبود شاهد به‌تنهایی نادرستی آن را اثبات نمی‌کند. پژوهش حاضر یک لایه راستی‌آزمایی مستقل پس از تولید پیشنهاد می‌کند که ادعاهای اتمی را از پاسخ استخراج می‌کند، آن‌ها را با قطعه شاهد و منبع پیوند می‌دهد، رابطه را در سه وضعیت «پشتیبانی‌شده»، «متناقض» و «فاقد شواهد کافی» طبقه‌بندی می‌کند و نتیجه را به سیاستی قابل توضیح، یعنی حفظ، اصلاح، بازیابی دوباره یا خودداری از پاسخ، می‌رساند. این رویکرد ادعای کشف نخستین راهکار ادعامحور نیست؛ پژوهش‌های اخیر بخش‌هایی از این مسئله را بررسی کرده‌اند. هدف نیز حذف مطلق خطا نیست؛ هدف آن است که ادعاهای بی‌پشتوانه تا حد ممکن شناسایی شوند، منبع تصمیم قابل بازبینی بماند و سامانه هنگام ناکافی بودن شواهد از قطعیت بی‌دلیل پرهیز کند. این مقاله چارچوب را طراحی و پروتکل ارزیابی آن را تعریف می‌کند و هیچ نتیجه تجربی تازه‌ای گزارش نمی‌کند.

کارهای گذشته

برای تدوین پیشینه، 25 منبع مرتبط که عمدتاً در سال‌های 2025 و 2026 منتشر شده‌اند به‌صورت هدفمند انتخاب شد و مقاله RAGTruth از سال 2024 به‌سبب نقش داده‌ای‌اش حفظ شد؛ این مرور روایی است و پوشش جامع همه مطالعات را ادعا نمی‌کند. سفر یک ادعا از متن پاسخ تا شاهد پشتیبان با تعریف مسئله آغاز می‌شود. Huang و همکاران (2025) در مروری جامع اصول، گونه‌شناسی، علت‌ها، روش‌های تشخیص و مسیرهای کاهش توهم را بررسی کردند و میان خطای واقع‌مندی و خطای وفاداری به زمینه تمایز قائل شدند؛ بر این اساس ارزیابی باید هم درستی بیرونی گزاره و هم سازگاری آن با شواهد مورد ادعا را بسنجد [1]. Heo و همکاران (2025) با HaluCheck سامانه‌ای توضیح‌پذیر ساختند که مؤلفه AutoFactNLI در آن پاسخ را به واقعیت‌های اتمی تقسیم و هر یک را جداگانه ارزیابی می‌کند و وضعیت گزاره‌ها را به‌صورت دیداری نشان می‌دهد؛ با این حال کیفیت داوری به صورت‌بندی ادعا و انتخاب مدل ارزیاب وابسته می‌ماند [2].

حال پرسش این است که شاهد چگونه به دست می‌آید. Li و همکاران (2026) چارچوب RAG-SC را با ترکیب بازیابی معنایی و مبتنی بر جنبه و اصلاح زنجیره استدلال پیشنهاد کردند و روی LaMP و HotpotQA بهبود 1.0 تا 30.3 درصد در معیارهای مختلف و کاهش زمان استنتاج تا 14.3 درصد گزارش کردند [3]. Peng و همکاران (2026) در QR^3AG با سنجش ارتباط پرسش و پاسخ اولیه درباره نیاز به بازیابی تصمیم گرفتند و افزایش 7.5

درصدی دقت داوری بازیابی و کاهش 50.5 درصدی نرخ بازیابی را گزارش کردند [4]. اما شاهد فقط به الگوریتم بازیابی وابسته نیست. Song (2026) نشان داد استفاده مستقیم از خروجی خام OCR می‌تواند پاسخ‌گویی را مختل کند و تبدیل آن به ساختار جدولی عملکرد را بهبود می‌دهد [5]. Qu و همکاران (2025) با روش PNCD در یک مطالعه موردی پزشکی کوشیدند اثر اطلاعات نویزی و تکراری بر استدلال مدل را کاهش دهند [6]. Zhao و همکاران (2026) نشان دادند افزودن دانش مخرب به یک RAG مبتنی بر گراف دانش می‌تواند عملکرد سامانه را مختل کند؛ بنابراین منشأ، زمان انتشار و هم‌سویی شاهد نیز باید بررسی شوند [7].

برای راستی‌آزمایی خود ادعاها، Zheng و همکاران (2026) در AFEV ادعاهای پیچیده را به واقعیت‌های اتمی تجزیه کردند و با رتبه‌بندی دوباره شواهد و اعتبارسنجی متناسب با هر واقعیت، آن را به‌صورت تکرارشونده بررسی کردند [8]. Xiong و همکاران (2025) در DelphiAgent از چند مدل زبانی و چند دور بازخورد استفاده کردند و روی RAWFC بهبود macF1 تا 6.84 درصد گزارش کردند، هرچند داوری چندعاملی زمان و هزینه را افزایش می‌دهد [9]. Rahman و همکاران (2026) روش‌های واقع‌مندی‌سنجی را مرور کردند و با برشمردن محدودیت‌های مجموعه‌داده‌ها و معیارها نتیجه گرفتند که ارزیابی باید چندمعیاره و همراه با بازبینی انسانی باشد [10]. Tikka و همکاران (2026) راهبردهای کاهش توهم را در سه کاربرد صنعتی بررسی کردند و نشان دادند نیاز هر کاربرد متفاوت است [11]. Elkiran و همکاران (2026) اثر روش بازیابی، بازرتبه‌بندی و معیار شباهت را در یک سامانه پرسش‌وپاسخ RAG به‌صورت تجربی سنجیدند، و چون کیفیت بازیابی می‌تواند نتیجه ارزیابی را تغییر دهد، تنظیمات بازیابی در مقایسه با خطوط مبنا باید ثابت بماند [12].

اما تا چه اندازه می‌توان به معیارها اعتماد کرد؟ Godbole و همکاران (2025) در «Verify with Caution» پنج معیار واقع‌مندی را روی 11 مجموعه‌داده ارزیابی و ناسازگاری معیارها و سوگیری نسبت به بازگویی‌های معنایی را گزارش کردند [13]. Dubanowska و همکاران (2025) با کنترل هم‌بستگی‌های کاذب نشان دادند عملکرد آشکارسازهای مبتنی بر نمایش با تغییر توزیع داده افت شدیدی پیدا می‌کند [14]. Krishna و همکاران (2025) مجموعه FRAMES شامل 824 پرسش را برای ارزیابی هم‌زمان واقع‌مندی، بازیابی و استدلال ساختند و دقت را از حدود 0.40 بدون بازیابی به 0.66 با خط لوله بازیابی چندمرحله‌ای رساندند [15]. برای مقابله با سوگیری داور، Li و همکاران (2026) در MARCH پاسخ را به گزاره‌های اتمی تقسیم کردند و عامل بررسی‌کننده را بدون دیدن متن پاسخ اولیه به ارزیابی شواهد گماردند؛ مدل 8 میلیارد پارامتری مجهز به این سازوکار در بنچمارک‌های مورد مطالعه با مدل‌های بسته قدرتمند رقابت کرد [16]. Jia و همکاران (2026) در EAEV تشخیص توهم را در سطح موجودیت با هم‌ترازی موجودیت‌های تولیدشده و زمینه شواهد دنبال کردند، اما این رویکرد روابط علی، شرطی و استدلال چندمرحله‌ای را پوشش نمی‌دهد [17].

در نهایت نوبت داده و مقیاس است. Niu و همکاران (2024) پیکره RAGTruth را با نزدیک به 18000 پاسخ تولیدشده و برچسب انسانی در سطح پاسخ و قطعه ارائه کردند [18]. Bergeron و همکاران (2025) در پیش‌چاپ HalluGuard مدلی استدلال‌گر و کوچک برای طبقه‌بندی جفت‌های سند ـ ادعا معرفی کردند که روی زیرمجموعه‌ای از RAGTruth به دقت متوازن 84.0 درصد و روی بنچمارک کامل به 75.7 درصد رسید [19]. Liu و همکاران (2025) نیز در Verify-E با رویکرد تجزیه، تعبیه و تعامل، تطبیق در فضای تعبیه را جایگزین استدلال متنی پرهزینه کردند تا کارایی را با دقت رقابتی همراه کنند [20]. افزون بر مطالعات یادشده، پژوهش‌های تازه‌تر نیز از زوایای دیگری به این

مسئله پرداخته‌اند. Mala و همکاران (2026) وفاداری پاسخ در RAG را روی HotpotQA و HaluBench با چند راهبرد بازیابی و ادغام و سه مدل 2 تا 8 میلیارد پارامتری سنجیدند و خطای بازیابی را از خطای تولید جدا کردند [21]. Zhang و همکاران (2025) در مروری در Computational Linguistics توهم در مدل‌های زبانی بزرگ را بررسی کردند [22]. Ge و همکاران (2026) در CHIME اثر توهم بر بازیابی چگال بدون نمونه آموزشی را با نمره شدت در سطح بند و شاخص افت بازیابی سنجیدند و روی هشت مجموعه BEIR میانگین بهبود 6.5 درصدی nDCG@10 را گزارش کردند [23]. Klesel و همکاران (2025) در یادداشتی کوتاه RAG را معرفی کردند [24]. Abdullahi و همکاران (2026) نیز مروری سامانمند بر توهم در مدل‌های زبانی بزرگ ارائه دادند [25]. با نگاهی به کل این مسیر، تعریف مسئله، بازیابی، تجزیه ادعا، داوری، معیارها و داده هر یک به‌تنهایی بررسی شده‌اند، اما در منابع بررسی‌شده ترکیبی که تفکیک تناقض از شواهد ناکافی، ثبت منشأ شاهد، سیاست اجرایی و سنجش هم‌زمان هزینه را یکجا بیاورد دیده نشد.

جدول 1 - پژوهش‌های اخیر در تشخیص توهم و راستی‌آزمایی ادعا در سامانه‌های RAG

مرجع	سال	روش	دیتاست	چالش	نتایج	شکاف	کد
[1]	2025	مرور جامع توهم	—	تعریف توهم	تمایز واقع‌مندی از وفاداری به زمینه	فاقد پروتکل سطح ادعا	—
[2]	2025	HaluCheck (واقعیت اتمی و NLI)	SelfCheckNLI	تشخیص توضیح‌پذیر	نمایش دیداری وضعیت ادعاها	وابسته به صورت‌بندی ادعا	—
[3]	2026	RAG-SC (بازیابی معنایی)	LaMP، HotpotQA	ناسازگاری دانش داخلی و بیرونی	بهبود 1.0 تا 30.3٪؛ کاهش 14.3٪ زمان	وابسته به معیار و بنچمارک	—
[4]	2026	QR³AG (آستانه ارتباط)	ReJudGE	بازیابی غیرضروری	+7.5٪ دقت داوری؛ −50.5٪ نرخ بازیابی	فاقد برچسب سه‌حالته	—
[5]	2026	ساختاربندی جدولی خروجی OCR	اسناد مالی تصویری	خروجی خام OCR	بهبود با ساختاربندی	محدود به نوع سند	—
[6]	2025	PNCD (کاهش نویز)	مطالعه موردی پزشکی	شواهد نویزی و تکراری	بهبود در محیط پرنویز	تعمیم آزموده نشده	—
[7]	2026	مسموم‌سازی دانش در KG RAG-	—	تزریق دانش مخرب	اهمیت اعتمادپذیری منبع	منشأ شاهد ارزیابی نشده	—
[8]	2026	AFEV (استخراج اتمی تکرارشونده)	—	ادعاهای پیچیده	راستی‌آزمایی ریزدانه	فاقد سیاست سه‌حالته و خودداری	—
[9]	2025	DelphiAgent (داوری چندعاملی)	RAWFC	وابستگی به داور منفرد	بهبود macF1 تا 6.84٪	هزینه بالا	—
[10]	2026	مرور واقع‌مندی‌سنجی	—	محدودیت داده و معیار	راهنمای ارزیابی چندمعیاره	روش جدید ندارد	—
[11]	2026	کاهش توهم در سه کاربرد صنعتی	سه کاربرد صنعتی	نیاز متفاوت هر کاربرد	بررسی در زمینه واقعی	راه‌حل همه‌منظوره ندارد	—
[12]	2026	بررسی تجربی بازیابی و بازرتبه‌بندی	سامانه پرسش‌وپاسخ RAG	اثر تنظیمات بازیابی	مقایسه کنترل‌شده	در سطح ادعا نیست	—
[13]	2025	ارزیابی پنج معیار واقع‌مندی	11 مجموعه‌داده	ناسازگاری معیارها	سوگیری نسبت به بازگویی معنایی	نیازمند اعتبارسنجی انسانی	—
[14]	2025	آشکارسازهای مبتنی بر نمایش	—	شکست در داده خارج از توزیع	ارزیابی واقع‌بینانه‌تر	افت شدید با تغییر توزیع	—
[15]	2025	FRAMES و بازیابی چندمرحله‌ای	FRAMES (824 پرسش)	ارزیابی هم‌زمان واقعیت و بازیابی	دقت از 0.40 به 0.66	فاقد برچسب سطح ادعا	HF
[16]	2026	MARCH (بررسی‌کننده مستقل)	—	سوگیری تأییدی	مدل 8B رقابتی با مدل‌های بسته	هزینه چندعاملی	—
[17]	2026	EAEV (هم‌ترازی موجودیت)	—	توهم در سطح موجودیت	پایداری در برابر تغییر شواهد	روابط علی و شرطی را پوشش نمی‌دهد	—

مرجع	سال	روش	دیتاست	چالش	نتایج	شکاف	کد
[18]	2024	پیکره RAGTruth	حدود 18 هزار پاسخ	نبود پیکره توهم برای RAG	برچسب سطح پاسخ و قطعه	نیازمند نگاشت به سه برچسب	—
[19]	2025	HalluGuard (پیش‌چاپ)	RAGTruth	طبقه‌بندی جفت سند ـ ادعا	BAcc برابر 84.0٪ و 75.7٪	فقط پیش‌چاپ	—
[20]	2025	Verify-E (تجزیه و تعبیه)	—	مقیاس‌پذیری	کارایی با دقت رقابتی	مصالحه عمق و هزینه	—
[21]	2026	ارزیابی تجربی وفاداری RAG با بازیابی تنک، چگال و ترکیبی	HotpotQA، HaluBench	توهم وفاداری ناشی از تعامل بازیابی و تولید	تفکیک خطای بازیابی از تولید	ارزیابی در سطح پاسخ	GitHub
[22]	2025	مرور ادبیات توهم در مدل‌های زبانی بزرگ	—	توهم در مدل‌های زبانی بزرگ	مرور جامع ادبیات	فاقد پروتکل سطح ادعا برای RAG	—
[23]	2026	CHIME (کاهش اثر توهم در بازیابی چگال)	8 مجموعه BEIR	اثر توهم بر کیفیت بازیابی	بهبود میانگین 6.5٪ nDCG@10	راستی‌آزمایی ادعای پاسخ نیست	—
[24]	2025	یادداشت معرفی RAG	—	معرفی مفهوم RAG	معرفی اجزای بازیابی، افزودن و تولید	فاقد ارزیابی تجربی	—
[25]	2026	مرور سامانمند توهم در مدل‌های زبانی بزرگ	—	توهم در مدل‌های زبانی بزرگ	مرور سامانمند و تحلیل عملکرد	روش جدیدی ارائه نمی‌کند	—

جدول 1 نشان می‌دهد پژوهش‌های اخیر هر یک بخشی از مسئله را هدف گرفته‌اند. تجزیه به واقعیت‌های اتمی در HaluCheck به کار رفته و کیفیت داوری آن به صورت‌بندی ادعا و انتخاب مدل ارزیاب وابسته است [2]. داوری چندعاملی در DelphiAgent دقت را بالا برده، اما هزینه و زمان را افزایش می‌دهد [9]. بهبود بازیابی در RAG-SC به افزایش دقت و کاهش زمان استنتاج رسیده است [3]. روش QR^3AG نیز هزینه بازیابی را کاهش داده، اما رابطه سه‌حالته ادعا و شاهد را بررسی نمی‌کند [4]. هم‌ترازی موجودیت در EAEV فقط بخشی از انواع ادعا را پوشش می‌دهد [17]. HalluGuard نتیجه خود را روی RAGTruth در قالب پیش‌چاپ گزارش کرده است [19]. Verify-E نیز کارایی را با دقت رقابتی دنبال می‌کند [20]. Mala و همکاران برچسب «پاسخ نکردن کالیبره‌شده» را در کنار پاسخ درست و توهم‌دار به کار برده‌اند، اما ارزیابی آن‌ها در سطح پاسخ است و نه ادعا [21]. CHIME نیز بر اثر توهم بر بازیابی تمرکز دارد و ادعاهای پاسخ را راستی‌آزمایی نمی‌کند [23]. اعداد این جدول روی مجموعه‌داده‌ها و وظایف متفاوت به‌دست آمده‌اند و مستقیماً قابل مقایسه نیستند. با این حال هیچ‌کدام تفکیک تناقض از شواهد ناکافی، ثبت پیوند ادعا ـ شاهد ـ منبع، تبدیل برچسب داوری به سیاست اجرایی و سنجش هم‌زمان کیفیت و هزینه را در یک لایه مستقل ترکیب نکرده‌اند و پژوهش حاضر برای پر کردن همین شکاف طراحی شده است؛ تازگی این ترکیب پس از پیاده‌سازی و مقایسه با نزدیک‌ترین روش‌ها باید سنجیده شود.

متدولوژی

روش پیشنهادی یک فرایند پنج‌مرحله‌ای پس از تولید است. ورودی آن سه‌تایی (q, D, y) شامل پرسش یا دستور q، مجموعه سندهای در اختیار مولد D و پاسخ تولیدشده y است و خروجی آن پاسخ نهایی $\hat{y}$ همراه با رکوردهای قابل ممیزی است. مراحل عبارت‌اند از تجزیه ادعا، بازیابی و پیوند شاهد، داوری سه‌حالته، اجرای سیاست و ارزیابی. مدل مولد ثابت است و لایه پیشنهادی فقط خروجی آن را بررسی می‌کند، بنابراین مقایسه حالت با راستی‌آزمایی و بدون آن همیشه روی همان پاسخ‌های مولد انجام می‌شود. چارچوب در دو حالت اجرا می‌شود. در حالت بسته شاهد فقط از D گرفته می‌شود تا وفاداری به زمینه سنجیده شود و در حالت باز شاهد از یک مخزن بیرونی ثابت بازیابی می‌شود تا درستی واقعی ادعا سنجیده شود؛ این تفکیک با تمایز خطای واقع‌مندی از خطای وفاداری به زمینه سازگار است [1]. چون چارچوب هنوز اجرا نشده است، همه مقادیر عددی این بخش مقدار اولیه‌اند و فقط روی داده توسعه تنظیم

می‌شوند.

در مرحله اول، تجزیه‌گر Dec پاسخ y را به مجموعه ادعاها تبدیل می‌کند.

$$A = Dec(y) = \{a1, a2, ..., an\},\quad n \le n_max = 40 \qquad (1)$$

هر ادعا باید سه ویژگی داشته باشد. ادعا اتمی است، یعنی فقط یک واقعیت قابل راستی‌آزمایی را بیان می‌کند. ادعا مستقل از متن است، یعنی ضمیرها و اشاره‌های آن به مصداق صریح تبدیل شده‌اند. ادعا بازه‌ای از y را که از آن استخراج شده است با آفست آغاز و پایان نویسه ثبت می‌کند. جمله‌های بیانگر نظر، تعارف و ساختار گفتار ادعای قابل بررسی حساب نمی‌شوند. ادعاهای علی، شرطی و عددی همراه با شرط یا واحد خود در یک ادعا می‌مانند، زیرا شکستن آن‌ها معنا را تغییر می‌دهد و هم‌ترازی موجودیت این روابط را پوشش نمی‌دهد [17]. تجزیه اتمی در HaluCheck به کار رفته است [2]. AFEV نیز همین ایده را برای ادعاهای پیچیده به کار برده است [8]. تجزیه با یک مدل زبانی، خروجی ساختاریافته JSON و دمای نمونه‌برداری صفر انجام می‌شود و چون خطای این مرحله به مراحل بعد منتقل می‌شود، کیفیت آن جداگانه سنجیده می‌شود.

در مرحله دوم، برای هر ادعا مجموعه شاهد جداگانه ساخته می‌شود. سندها به قطعه‌هایی با طول تقریبی 200 توکن و هم‌پوشانی 50 توکن تقسیم می‌شوند و داده‌های ساختاریافته مانند رکوردهای JSON پیش از تقسیم به جمله‌های «کلید: مقدار» تبدیل می‌شوند. در حالت بسته مخزن قطعه‌ها فقط قطعه‌های D است و در حالت باز یک نسخه ثابت و تاریخ‌دار از مخزن بیرونی است. بازیابی ترکیبی است: رتبه‌بندی واژگانی BM25 و رتبه‌بندی چگال با یک مدل تعبیه چندزبانه (برای نمونه M3-BGE) با ترکیب رتبه‌ای متقابل به هم می‌رسند.

$$score(e) = \Sigma_\{r \in R\}\, 1 / (60 + rank_r(e)) \qquad (2)$$

در رابطه 2، R مجموعه فهرست‌های رتبه‌بندی و rank_r(e) رتبه قطعه e در فهرست r است. پرسش بازیابی از الحاق متن ادعا و پرسش q ساخته می‌شود. k = 20 قطعه برتر با یک بازرتبه‌بند متقاطع دوباره امتیازدهی می‌شود و m = 5 قطعه برتر به‌عنوان مجموعه شاهد E_a ادعا نگه داشته می‌شود؛ در حالت بسته k برابر کمینه 20 و تعداد قطعه‌های D است. تنظیمات بازیابی، بازرتبه‌بندی و معیار شباهت برای همه روش‌ها و خطوط مبنا یکسان می‌ماند، چون این تنظیمات بر نتیجه ارزیابی اثر دارند [12]. برای هر پیوند ادعا ـ شاهد یک رکورد با فیلدهای شناسه ادعا، شناسه قطعه، شناسه سند، منشأ منبع، زمان انتشار، امتیاز بازیابی، امتیاز بازرتبه‌بندی و رتبه ثبت می‌شود. منشأ و زمان انتشار به داور داده می‌شوند و در گزارش نهایی می‌مانند، زیرا دانش مخرب واردشده به مخزن می‌تواند نتیجه را منحرف کند [7].

در مرحله سوم، یک داور مستقل برچسب هر ادعا را از مجموعه {S, C, N} (پشتیبانی‌شده، متناقض، فاقد شواهد کافی) تعیین می‌کند. تعریف برچسب‌ها صوری است. برچسب S زمانی داده می‌شود که زیرمجموعه‌ای از شواهد ادعا را نتیجه بدهد، برچسب C زمانی که زیرمجموعه‌ای از شواهد با ادعا ناسازگار باشد و برچسب N در غیر این صورت.

$$\ell(a)=S \Leftrightarrow \exists E' \subseteq E_a:\ E' \vDash a;\quad \ell(a)=C \Leftrightarrow \exists E' \subseteq E_a:\ E' \vDash \neg a;\quad \text{else } \ell(a)=N \qquad (3)$$

اگر هر دو شرط S و C هم‌زمان برقرار باشند، برچسب C با پرچم mixed = 1 ثبت می‌شود تا تعارض میان منابع پنهان نماند. داور می‌تواند چند قطعه را برای نتیجه‌گیری ترکیب کند، چون پرسش‌های FRAMES به ترکیب چندمرحله‌ای اطلاعات نیاز دارند [15]. نبود شاهد هرگز به برچسب C منجر نمی‌شود. داور از خانواده‌ای متفاوت از مدل مولد انتخاب می‌شود تا سوگیری خودپسندی کاهش یابد، و فقط ادعا، مجموعه شاهد و فراداده آن را می‌بیند و به متن

پاسخ اولیه دسترسی ندارد؛ جداکردن بررسی‌کننده از پاسخ اولیه در MARCH برای مقابله با سوگیری تأییدی به کار رفته است [16]. خروجی داور JSON با فیلدهای برچسب، شناسه‌های شاهد پشتیبان، شناسه‌های شاهد ناقض و توضیح حداکثر 40 کلمه‌ای است. پرامپت شامل تعریف برچسب‌ها و چند مثال برای هر برچسب است، به‌ویژه مثال‌هایی که تفاوت C و N را نشان می‌دهند، و پیش از اجرای آزمون نهایی ثابت می‌شود. برای سنجش اطمینان، ادعا $s = 5$ بار با دمای 0.7 داوری می‌شود و نسبت رأی‌های هم‌سو با رأی اکثریت به‌عنوان اطمینان ثبت می‌شود.

$$c(a) = (1/s)\ \Sigma_{j=1..s}\ 1[\ \ell_j(a) = \ell_{maj}(a)\ ] \quad (4)$$

ادعایی که $c(a$) آن کمتر از آستانه τ باشد در اجرای پیش‌فرض با برچسب N در نظر گرفته می‌شود و τ روی داده توسعه تنظیم می‌شود. حالت بدون نمونه‌برداری چندباره نیز به‌عنوان تحلیل حذف سنجیده می‌شود. هزینه داوری چندعاملی یا چنددوری بالاست [9]، بنابراین هزینه هر حالت جداگانه گزارش می‌شود.

در مرحله چهارم، برچسب هر ادعا به یک سیاست اجرایی تبدیل می‌شود. ادعای S حفظ می‌شود. برای ادعای C یک بازنویس فقط با شاهد ناقض ادعای اصلاح‌شده a' را تولید می‌کند و a' باید دوباره داوری شود و برچسب S بگیرد، وگرنه حذف می‌شود. برای ادعای N متن ادعا با یک بازنویس پرسش بازنویسی می‌شود، بازیابی با k دو برابر تکرار می‌شود و داوری دوباره انجام می‌شود؛ این چرخه تا حداکثر $T_{max} = 2$ دور ادامه می‌یابد و ادعایی که پس از آن هنوز N بماند «غیرقابل تأیید» ثبت می‌شود. نسبت ادعاهای غیرقابل تأیید یا حذف‌شده به کل ادعاها سنجیده می‌شود.

$$u(y) = |\{\ a \in A : \mathrm{status}(a) \in \{\mathrm{unverifiable}, \mathrm{deleted}\}\ \}| \ /\ n \quad (5)$$

اگر $u(y) \geq \rho$ باشد سامانه از پاسخ قطعی خودداری می‌کند و در غیر این صورت $\hat{y}$ از ادعاهای حفظ‌شده و اصلاح‌شده ساخته می‌شود و ادعاهای غیرقابل تأیید با عبارت عدم قطعیت علامت می‌خورند. سازنده پاسخ فقط اجازه استفاده از همین ادعاها را دارد و حق افزودن اطلاعات تازه ندارد. $\hat{y}$ یک بار دوباره تجزیه و داوری می‌شود و اگر ادعایی با برچسب غیر از S پیدا شود، سامانه خودداری می‌کند. سه گونه رفتار برای ادعای غیرقابل تأیید (حذف، علامت‌گذاری، خودداری) به‌صورت جداگانه آزموده می‌شوند.

مجموعه‌داده‌ها در مرحله پنجم سه‌گانه‌اند. RAGTruth شامل 2965 نمونه و 17790 پاسخ تولیدشده توسط شش مدل در سه وظیفه پرسش‌وپاسخ، داده‌به‌متن و خلاصه‌سازی است و برچسب انسانی در سطح کلمه با چهار نوع تعارض آشکار، تعارض ظریف، اطلاعات بی‌پشتوانه آشکار و اطلاعات بی‌پشتوانه ظریف دارد [18]. تقسیم رسمی آن 15090 نمونه آموزش و 2700 نمونه آزمون است و ارزیابی در حالت بسته انجام می‌شود. HaluBench فقط برچسب وفاداری در سطح پاسخ دارد و ادعاهای آن باید با تجزیه تکمیل شوند [21]. FRAMES شامل 824 پرسش چندمرحله‌ای است و در حالت باز روی یک نسخه ثابت از مخزن ویکی‌پدیا اجرا می‌شود؛ پاسخ‌ها با یک یا چند مولد در سه شرایط بدون بازیابی، بازیابی تک‌مرحله‌ای و بازیابی چندمرحله‌ای تولید می‌شوند [15].

برچسب حقیقی هر ادعا در RAGTruth از هم‌پوشانی بازه ادعا با بازه‌های برچسب‌خورده ساخته می‌شود. بازه برچسب‌خورده h با ادعای a هم‌پوشان است اگر $|\mathrm{span}(a) \cap h| \ /\ |h|$ حداقل 0.5 باشد. ادعایی که با بازه‌ای از نوع تعارض هم‌پوشان است برچسب C می‌گیرد، ادعایی که فقط با بازه بی‌پشتوانه هم‌پوشان است برچسب N می‌گیرد و بقیه ادعاها برچسب S می‌گیرند؛ اگر هر دو نوع هم‌پوشان باشند C اولویت دارد. برچسب‌های تطبیقی پیکره مانند implicit_true و due_to_null طبق راهنمای رسمی پیکره اعمال و تصمیم ثبت می‌شود. چون نگاشت بازه کلمه به

ادعا تقریبی است، همه نتایج در سطح ادعا، در سطح پاسخ (پاسخ مثبت است اگر دست‌کم یک ادعای C یا N داشته باشد) و در سطح بازه نیز گزارش می‌شوند.

برای سنجش خطای مراحل میانی سه بازبینی انسانی تعریف می‌شود. در بازبینی تجزیه، 100 پاسخ نمونه‌برداری‌شده توسط دو نفر برای اتمی بودن، پوشش و وفاداری ادعاها بررسی می‌شود. در بازبینی داوری، 300 جفت ادعا ـ شاهد با نمونه‌گیری طبقه‌ای از سه برچسب و سه مجموعه‌داده توسط دو نفر برچسب می‌خورند و حاشیه خطای تقریبی ±5.7 درصد برای نسبت 0.5 با اطمینان 95 درصد به‌دست می‌آید. در بازبینی ارجاع، درستی شاهد ثبت‌شده برای هر ادعا بررسی می‌شود. توافق بازبین‌ها با ضریب کاپای کوهن گزارش می‌شود و چون معیارهای خودکار واقع‌مندی ناسازگارند، نتیجه بازبینی انسانی بر معیار خودکار اولویت دارد [13].

معیارهای ارزیابی چهار گروه‌اند. گروه اول معیارهای تشخیص در سطح ادعا است. ادعای بی‌پشتوانه (C یا N) مثبت حساب می‌شود و دقت، فراخوانی و F1 از رابطه‌های زیر به‌دست می‌آیند. F1 ماکرو روی سه برچسب و ماتریس درهم‌ریختگی نیز گزارش می‌شود.

$$P=TP/(TP+FP),\ R=TP/(TP+FN),\ F1=2PR/(P+R),\ \text{Macro-F1}=(1/3)\Sigma_{c\in\{S,C,N\}}\,F1_c \quad (6)$$

گروه دوم صحت ارجاع است. در FRAMES بازیابی مقاله‌های مرجع در میان شواهد ثبت‌شده سنجیده می‌شود و در دو مجموعه دیگر دقت ارجاع از بازبینی انسانی به‌دست می‌آید. گروه سوم کیفیت خودداری است. پوشش Cov نسبت پاسخ‌های داده‌شده، SelAcc دقت روی پاسخ‌های داده‌شده، HAR نرخ پاسخ نادرست داده‌شده و UAR نرخ خودداری از پاسخی است که پیش از راستی‌آزمایی درست بوده است. منحنی ریسک ـ پوشش با تغییر ρ ساخته می‌شود و مساحت زیر آن گزارش می‌شود.

$$\text{Cov}=|\text{answered}|/|\text{all}|,\ \text{SelAcc}=|\text{answered}\wedge\text{correct}|/|\text{answered}|,\ \text{HAR}=P(\text{answered}\wedge\text{wrong}),\ \text{UAR}=P(\text{abstain}\mid\text{original correct}) \quad (7)$$

گروه چهارم هزینه اجرا است. تعداد فراخوانی مدل، توکن ورودی و خروجی و زمان پاسخ برای هر پاسخ ثبت می‌شود و هزینه نسبی از رابطه زیر به‌دست می‌آید.

$$C_{rel} = (T_{in} + T_{out})_{verify} / (T_{in} + T_{out})_{generation} \quad (8)$$

خطوط مبنا و تحلیل‌های حذف برای آزمودن سهم هر مؤلفه طراحی شده‌اند. خط مبنای اول پاسخ بدون راستی‌آزمایی است. خط مبنای دوم داوری در سطح کل پاسخ با همان مدل داور است. خط مبنای سوم داوری در سطح ادعا با دو وضعیت (پشتیبانی‌شده و غیر آن) است که سودمندی تفکیک C از N را مستقیماً می‌سنجد. خط مبنای چهارم HalluGuard است که جفت‌های سند ـ ادعا را طبقه‌بندی می‌کند [19]. در تحلیل‌های حذف، به‌ترتیب تجزیه، بازرتبه‌بندی، فراداده منشأ، بازیابی دوباره ($T_{max} = 0$)، نمونه‌برداری چندباره و مدل داور تغییر داده یا حذف می‌شوند. همه خطوط مبنا روی همان داده و تنظیمات بازیابی اجرا می‌شوند.

برای تنظیم ابرپارامترها 10 درصد داده آموزش RAGTruth با نمونه‌گیری طبقه‌ای بر اساس وظیفه و مدل مولد، و 20 درصد پرسش‌های FRAMES (165 پرسش) با بذر ثابت به‌عنوان داده توسعه کنار گذاشته می‌شود. فضای جست‌وجو برای k برابر $\{10, 20, 50\}$، برای m برابر $\{3, 5, 8\}$، برای T_{max} برابر $\{0, 1, 2\}$، برای ρ برابر $\{0.1, 0.2, 0.3, 0.4, 0.5\}$ و برای τ برابر $\{0.4, 0.6, 0.8\}$ است و داده آزمون فقط یک بار بعد از قفل شدن پرامپت‌ها و ابرپارامترها استفاده می‌شود. فاصله اطمینان 95 درصد با خودگردان‌سازی با 10000 بازنمونه‌گیری و با خوشه‌بندی

بر اساس نمونه ورودی محاسبه می‌شود، چون شش پاسخ هر نمونه RAGTruth زمینه مشترک دارند. مقایسه روش‌ها با خودگردان‌سازی جفتی و برای برچسب دوتایی سطح پاسخ با آزمون مک‌نمار انجام می‌شود و چندین مقایسه با تصحیح هولم تعدیل می‌شوند. اجزای نمونه‌برداری‌شده با سه بذر مستقل اجرا و میانگین و انحراف معیار گزارش می‌شوند.

برای بازتولیدپذیری، هر مرحله خروجی خود را به‌صورت JSON با شناسه یکتا ذخیره می‌کند تا هر ادعای نهایی تا پاسخ اولیه ردیابی شود. نام و نسخه مدل‌ها، تاریخ اجرا، بذرها، چکیده درهم‌ساز نسخه مخزن ویکی‌پدیا و پرامپت‌ها ثبت می‌شوند و فراخوانی‌های مدل با کلید درهم‌ساز ورودی نگهداری می‌شوند تا اجرای دوباره بدون فراخوانی تازه ممکن باشد. کد، پرامپت‌ها و گزارش‌های میانی در یک مخزن عمومی نگهداری می‌شوند.

تهدیدهای روایی طراحی شناخته‌شده‌اند. خطای تجزیه به مراحل بعد منتقل می‌شود، داور ممکن است سوگیری داشته باشد، نگاشت برچسب‌های RAGTruth به سه وضعیت تقریبی است و عملکرد آشکارسازها با تغییر توزیع داده افت می‌کند [14]. برای کنترل این تهدیدها بازبینی انسانی، گزارش جداگانه هر سطح ارزیابی و آزمودن چند مدل داور پیش‌بینی شده است. نتایج روی مجموعه‌داده‌ها و وظایف متفاوت نیز مستقیماً قابل مقایسه نیستند و تعمیم آن‌ها به دامنه‌های دیگر باید جداگانه آزموده شود.

منابع

[1] Huang, L., Yu, W., Ma, W., Zhong, W., Feng, Z., Wang, H., Chen, Q., Peng, W., Feng, X., Qin, B., & Liu, T. (2025). A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions. ACM Transactions on Information Systems, 43(2), Article 42. https://doi.org/10.1145/3703155

[2] Heo, S., Son, S., & Park, H. (2025). HaluCheck: Explainable and verifiable automation for detecting hallucinations in LLM responses. Expert Systems with Applications, 272, 126712. https://doi.org/10.1016/j.eswa.2025.126712

[3] Li, Y., Ke, W., Liu, J., Wang, P., Liu, J., & He, Y. (2026). Towards evidence-aware retrieval-augmented generation via self-corrective chain-of-thought. Information Processing & Management, 63(2), 104369. https://doi.org/10.1016/j.ipm.2025.104369

[4] Peng, S., Zhang, W., Li, S., & Qu, D. (2026). QR³AG: Dynamic Retrieval-Augmented Generation via Query-Response Relevance Threshold Judgement. Expert Systems with Applications, 299, 130087. https://doi.org/10.1016/j.eswa.2025.130087

[5] Song, M. (2026). Defining the problem: The impact of OCR quality on retrieval-augmented generation performance and strategies for improvement. Information Processing & Management, 63(1), 104368. https://doi.org/10.1016/j.ipm.2025.104368

[6] Qu, J., Liu, J., Liu, X., Chen, M., Li, J., & Wang, J. (2025). PNCD: Mitigating LLM hallucinations in noisy environments—A medical case study. Information Fusion, 123, 103328. https://doi.org/10.1016/j.inffus.2025.103328

[7] Zhao, T., Chen, J., Ru, Y., Zhu, H., Hu, N., Liu, J., & Lin, Q. (2026). Exploring knowledge poisoning attacks to retrieval-augmented generation. Information Fusion, 127, 103900. https://doi.org/10.1016/j.inffus.2025.103900

[8] Zheng, L., Li, C., Liu, Z., Huang, F., Jia, H., Ye, Z., & Zhang, X. (2026). Fact in fragments: Deconstructing complex claims via LLM-based atomic fact extraction and verification. Expert Systems with Applications. https://doi.org/10.1016/j.eswa.2025.130572

[9] Xiong, C., Zheng, G., Ma, X., Li, C., & Zeng, J. (2025). DelphiAgent: A trustworthy multi-agent verification framework for automated fact verification. Information Processing & Management, 62(6), 104241. https://doi.org/10.1016/j.ipm.2025.104241

[10] Rahman, S. S., Islam, M. A., Alam, M. M., Zeba, M., Rahman, M. A., et al. (2026). Hallucination to truth: A review of fact-checking and factuality evaluation in large language models. Artificial Intelligence Review, 59, Article 70. https://doi.org/10.1007/s10462-025-11454-w

[11] Tikka, P., Karjalainen, J., Alesani, A., & Goriachev, V. (2026). Large language model hallucination mitigation in three industrial use cases. IEEE Access, 14, 25564–25576. https://doi.org/10.1109/ACCESS.2026.3659997

[12] Elkiran, H., & Rasheed, J. (2026). An Empirical Evaluation of Retrieval, Reranking, and Similarity for a Q&A-Based Retrieval Augmented Generation System. IEEE Access, 14, 26053–26066. https://doi.org/10.1109/ACCESS.2026.3664852

[13] Godbole, A., & Jia, R. (2025). Verify with Caution: The Pitfalls of Relying on Imperfect Factuality Metrics. Findings of the Association for Computational Linguistics: ACL 2025, 22889–22912. https://doi.org/10.18653/v1/2025.findings-acl.1175

[14] Dubanowska, Z., Żelaszczyk, M., Brzozowski, M., Mandica, P., & Karpowicz, M. P. (2025). Representation-based Broad Hallucination Detectors Fail to Generalize Out of Distribution. Findings of EMNLP 2025, 17563–17575. https://doi.org/10.18653/v1/2025.findings-emnlp.952

[15] Krishna, S., Krishna, K., Mohananey, A., Schwarcz, S., Stambler, A., Upadhyay, S., & Faruqui, M. (2025). Fact, Fetch, and Reason: A Unified Evaluation of Retrieval-Augmented Generation. Proceedings of NAACL-HLT 2025, 4745–4759. https://doi.org/10.18653/v1/2025.naacl-long.243

[16] Li, Z., Zhang, Y., Cheng, P., Song, J., Zhou, M., Li, H., Hu, S., Qin, Y., Zhao, E., Jiang, X., & Jiang, G. (2026). MARCH: Multi-Agent Reinforced Check for Hallucination. Proceedings of ACL 2026, 39389–39415. https://doi.org/10.18653/v1/2026.acl-long.1828

[17] Jia, R., Fang, Z., Wu, M., Lu, J., & Zhang, Y. (2026). Evidence-Aligned Entity Verification for Hallucination Detection in Retrieval-Augmented Generation. Findings of ACL 2026, 29538–29554. https://doi.org/10.18653/v1/2026.findings-acl.1477

[18] Niu, C., Wu, Y., Zhu, J., Xu, S., Shum, K., Zhong, R., Song, J., & Zhang, T. (2024). RAGTruth: A Hallucination Corpus for Developing Trustworthy Retrieval-Augmented Language Models. Proceedings of ACL 2024, 10862–10878. https://doi.org/10.18653/v1/2024.acl-long.585

[19] Bergeron, L., Buhnila, I., François, J., & State, R. (2025). HalluGuard: Evidence-Grounded Small Reasoning Models to Mitigate Hallucinations in Retrieval-Augmented Generation. arXiv:2510.00880. https://arxiv.org/abs/2510.00880

[20] Liu, Z., Xue, J., Yang, X., Du, W., Fu, J., Chen, J., Guo, W., & Wang, Y. (2025). E-Verify: A Paradigm Shift to Scalable Embedding-based Factuality Verification. Findings of the Association for Computational Linguistics: EMNLP 2025, 5759–5776. https://doi.org/10.18653/v1/2025.findings-emnlp.308

[21] Mala, C. S., Gezici, G., & Giannotti, F. (2026). Disentangling Faithfulness Hallucinations in Retrieval-Augmented Generation: A Systematic Benchmark and Analysis. Machine Learning, 115(8), Article 187. https://doi.org/10.1007/s10994-026-07121-y

[22] Zhang, Y., Li, Y., Cui, L., Cai, D., Liu, L., Fu, T., Huang, X., Zhao, E., Zhang, Y., Chen, Y., Wang, L., Luu, A. T., Bi, W., Shi, F., & Shi, S. (2025). Siren's Song in the AI Ocean: A Survey on Hallucination in Large Language Models. Computational Linguistics, 51(4), 1373–1418. https://doi.org/10.1162/COLI.a.16

[23] Ge, X., & Xu, G. (2026). Contrastive hallucination impact mitigation and evaluation for zero-shot dense retrieval systems. Knowledge and Information Systems, 68, Article 274. https://doi.org/10.1007/s10115-026-02892-1

[24] Klesel, M., & Wittmann, H. F. (2025). Retrieval-Augmented Generation (RAG). Business & Information Systems Engineering, 67, 551–561. https://doi.org/10.1007/s12599-025-00945-3

[25] Abdullahi, S., Danyaro, K. U., & Chiroma, H. (2026). The rise of hallucination in large language models: systematic reviews, performance analysis and challenges. Cluster Computing, 29, Article 124. https://doi.org/10.1007/s10586-025-05891-z